

Cheat Sheet de Machine Learning

Conceptos prácticos y transversales a todo el curso.

Contenido

01 Sesgo y varianza (bias-variance tradeoff)

02 Datos desbalanceados y métricas de clasificación

03 Reducción de dimensionalidad con PCA

04 Teorema de Bayes y clasificador Naïve Bayes

05 Análisis de regresión

06 Regularización en ML

07 Redes neuronales convolucionales: bloques básicos

08 CNNs famosas

09 Aprendizaje por ensamble

10 Estructuras de datos

01

Sesgo y varianza (bias-variance tradeoff)

Sesgo y varianza

Sesgo (bias): error entre la predicción promedio del modelo y el valor real — mide qué tan bien representa la relación real

Varianza: cuánto cambia la predicción entre distintos conjuntos de entrenamiento — mide su sensibilidad a los datos

Alto sesgo → modelo demasiado simple → subajuste: error alto en entrenamiento y en prueba

Alta varianza → modelo demasiado complejo → sobreajuste: error bajo en entrenamiento, alto en prueba

Error total = Sesgo² + Varianza + Error irreducible

El mejor modelo es el que minimiza esta suma.

El tablero de dardos

Cada panel es un modelo distinto; el centro es el valor real

Sesgo = qué tan lejos del centro está el grupo de predicciones

Varianza = qué tan dispersas están las predicciones entre sí

El panel ideal (arriba-izq.): cerca del centro y poco disperso




Subajuste, ajuste correcto y sobreajuste

Grado 1: no logra capturar la curva → error alto en entrenamiento y en prueba (subajuste)

Grado 15: casi toca cada punto de entrenamiento, pero oscila entre ellos → error de prueba mucho mayor (sobreajuste)

Grado 4: el mejor balance — error bajo y similar en ambos conjuntos



02

**Datos desbalanceados y
métricas de clasificación**

Más allá de la exactitud (accuracy)

Un clasificador que siempre predice la clase mayoritaria puede tener accuracy alta sin haber aprendido nada.

Métrica	Fórmula	Responde a
Exactitud	$(TP+TN) / \text{Total}$	¿Qué % total acerté?
Precisión	$TP / (TP+FP)$	De lo que predije positivo, ¿cuánto era real?
Recall / Sensibilidad	$TP / (TP+FN)$	De los positivos reales, ¿cuántos detecté?
Especificidad	$TN / (TN+FP)$	De los negativos reales, ¿cuántos identifiqué?
F1 Score	$2 \cdot (Prec \cdot Rec) / (Prec + Rec)$	Media armónica entre precisión y recall



Soluciones: replicar datos, generar datos sintéticos (SMOTE), ponderar la pérdida (class_weight), o aumentar la complejidad del modelo.

Clasificador ingenuo vs. modelo real

Ambos alcanzan $\approx 95\%$ de exactitud, pero ninguno detecta la clase minoritaria (precisión y recall = 0)

La regresión logística, sin ajustes, imita al clasificador ingenuo frente a un desbalance fuerte

La exactitud sola puede ocultar que un modelo no aprendió nada útil sobre la clase que más importa



03

**Reducción de dimensionalidad
con PCA**

¿Qué es PCA?

Busca un nuevo conjunto de ejes ortogonales donde la varianza de los datos es máxima

Ordena los ejes de mayor a menor varianza (mayor varianza = más información)


Pasos: estandarizar los datos → calcular la matriz de covarianza → descomponer en autovalores y autovectores → ordenar de mayor a menor

Reducir dimensionalidad = conservar solo los primeros m ejes (los de mayor varianza)

PCA en acción

La flecha coral (componente 1) capta la mayor parte de la varianza de los datos

Quedarse solo con la componente 1 reduce a 1 dimensión conservando la mayoría de la información original



Cada componente es un nuevo eje de los datos

Un componente combina las variables originales con distintos pesos; no es una variable original seleccionada.

- PC1** Captura la mayor varianza posible: es la dirección principal de dispersión.
- PC2** Es perpendicular a PC1 y captura la mayor varianza que queda.
- PC3, ...** Siguen el mismo criterio: son ortogonales a los anteriores y explican cada vez menos varianza.

Pesos del eje $\neq$ puntuaciones de los datos: los pesos definen la combinación; las puntuaciones son las coordenadas de cada observación al proyectarla.

Los componentes se convierten en nuevas variables

1. Elegir cuántos conservar

Revisar la varianza explicada acumulada y retener k componentes según la pérdida de información aceptable.

2. Proyectar las observaciones

Multiplicar los datos centrados o estandarizados por los k ejes: $Z = X_{\text{preparada}} \cdot W_k$. El resultado tiene k columnas.

3. Utilizar la representación reducida

Usar Z para visualizar en 2D/3D, agrupar datos o entrenar un modelo; evaluar si la reducción ayuda a la tarea.

4. Transformar los datos nuevos

Ajustar el preprocesamiento y PCA solo con entrenamiento. En validación y prueba, reutilizar ese mismo ajuste.

Reducir dimensiones conserva variación, pero no garantiza mejorar la predicción.

04

Teorema de Bayes y Clasificador Naïve Bayes

Teorema de Bayes

$$P(A|B) = P(B|A) \times P(A) / P(B)$$

posterior = verosimilitud $\times$ prior / evidencia

$P(A)$ es la creencia inicial (prior); $P(A|B)$ es la creencia actualizada al observar B (posterior)

Ejemplo: $P(\text{fuego})=1\%$, $P(\text{humo})=10\%$, $P(\text{humo}|\text{fuego})=90\% \rightarrow P(\text{fuego}|\text{humo})=9\%$

MAP (máximo a posteriori): incorpora un prior — maximiza $P(y) \cdot \prod P(x_i|y)$


MLE (máxima verosimilitud): asume prior uniforme — maximiza solo $\prod P(x_i|y)$

Naïve Bayes: asume que las características son condicionalmente independientes dado y

Cómo cambia la creencia con evidencia

Antes de ver humo: 1% de probabilidad de fuego (prior)

Después de ver humo: 9% (posterior) — la evidencia multiplicó por 9 la creencia inicial



05

Análisis de regresión

Tipos de regresión


Tipo	Ajusta	Error minimizado
Lineal	Una línea	Suma de error cuadrático medio
Polinomial	Un polinomio de grado k	Suma de error cuadrático medio
Ridge	Línea / polinomio	Error cuadrático + norma L2 (β)
LASSO	Línea / polinomio	Error cuadrático + norma L1 (β)
Logística	Línea / polinomio + sigmoide	Entropía cruzada binaria

Ridge y LASSO se profundizan en el siguiente tema (Regularización).

Comparación visual sobre los mismos datos

Mismos datos y mismo grado polinomial (salvo la lineal) para las cuatro curvas


Ridge y LASSO producen curvas algo más suaves al penalizar coeficientes grandes



Regresión logística: ajuste de una sigmoide

La sigmoide convierte cualquier valor en una probabilidad entre 0 y 1

El umbral de decisión típico es 0.5 (línea punteada)



06

Regularización en ML

Reducir varianza a cambio de sesgo

L2 (Ridge): penaliza el cuadrado de los coeficientes $\rightarrow$ los encoge, rara vez los anula

L1 (LASSO): penaliza el valor absoluto $\rightarrow$ fuerza coeficientes a exactamente cero (selección automática de variables)

A mayor λ (fuerza de regularización) $\rightarrow$ mayor sesgo, menor varianza

K-fold CV: divide en k grupos, entrena en $k-1$, evalúa en 1, repite k veces


Dropout: desactiva aleatoriamente un % de conexiones en cada iteración de entrenamiento

L1 vs. L2: el efecto sobre los coeficientes


Líneas índigo = variables informativas · líneas grises = ruido

Ridge (L2): a mayor λ , encoge todos los coeficientes, casi nunca los anula


LASSO (L1): varios coeficientes de ruido llegan a exactamente cero



Validación cruzada y Dropout



Cada partición sirve una vez como prueba: se usa todo el dataset para validar, sin dejar datos sin ver.



En cada iteración se apagan conexiones distintas al azar, evitando que la red dependa de unas pocas neuronas.

07

Redes Neuronales Convolucionales: Bloques Básicos


Los bloques de una CNN

Bloque	Tipo	Propósito
Convolutacional	Entrenable	Detecta patrones locales (bordes, texturas)
Totalmente conectada	Entrenable	Combina linealmente todas las entradas
Pooling (Max/Avg)	No entrenable	Reduce el tamaño espacial del mapa
Normalización	Entrenable	Estabiliza la escala de las activaciones
Activación	No entrenable	Introduce no-linealidad
Función de pérdida	—	Cuantifica el error de la predicción

La operación de convolución

El kernel se desliza sobre la entrada calculando un producto punto en cada posición


Este kernel resalta bordes verticales (transiciones de claro a oscuro)



Max-Pooling

Conserva el valor máximo de cada ventana 2×2 — no tiene parámetros entrenables


Reduce el tamaño espacial (aquí de 6×6 a 3×3) y con ello el cómputo de las capas siguientes



Funciones de activación

ReLU es la más usada en capas ocultas


Sigmoid/Tanh saturan en los extremos y se usan menos en redes profundas



Funciones de pérdida

MSE/MAE/Huber: para regresión — penalizan la distancia entre el valor real y el predicho

Cross-Entropy: para clasificación — penaliza según la probabilidad asignada a la clase correcta



08

CNNs Famosas

AlexNet, VGGNet, ResNet, Inception

2012 · AlexNet

5 conv + 3 FC, ReLU — ganó el reto ImageNet

2015 · ResNet

Conexiones de atajo (skip connections) — resuelve el gradiente que desaparece en redes muy profundas

2014 · VGGNet

Kernels 3×3 uniformes — busca reducir parámetros


2014 · Inception / GoogLeNet

Varios tamaños de kernel en paralelo, concatenados — captura features a distintas escalas

Bloque residual vs. módulo Inception

ResNet: la conexión de atajo deja que la capa aprenda solo el residuo $f(x)$, facilitando entrenar redes muy profundas


Inception: aplica varios tamaños de kernel en paralelo y concatena sus salidas, capturando patrones a distintas escalas



Comparación de arquitecturas

Inception logra una precisión mayor que VGGNet con
~20 veces menos parámetros

Más parámetros no siempre significa mejor
arquitectura — el diseño importa más que el tamaño



09

Aprendizaje por Ensamble


Bagging, Boosting, Stacking

Bagging		Boosting		Stacking	
Se enfoca en	Reducir varianza	Se enfoca en	Reducir sesgo	Se enfoca en	Mejorar exactitud
Modelos débiles	Homogéneos	Modelos débiles	Homogéneos	Modelos débiles	Heterogéneos
Se combinan por	Votación simple	Se combinan por	Votación ponderada	Se combinan por	Meta-modelo aprendido

Exactitud y variabilidad

Bagging reduce la variabilidad frente al árbol único, al promediar sobre 100 árboles distintos

Stacking combina la mayor exactitud promedio con la menor variabilidad de las cuatro opciones



10

Estructuras de Datos

Lista, Pila, Cola, Árbol, Grafo, Tabla Hash

Lista/Arreglo: colección ordenada, acceso por índice

Pila (LIFO) y Cola (FIFO): push/pop vs. enqueue/dequeue — la cola la usa BFS

Árbol: jerarquía sin ciclos · Grafo: vértices y aristas, puede tener ciclos

Tabla hash: pares clave-valor, acceso en tiempo constante promedio

Estructura	Acceso	Búsqueda	Inserción
Lista / Arreglo	$O(1)$	$O(n)$	$O(n)$
Pila / Cola	$O(n)$	$O(n)$	$O(1)$
Tabla hash	—	$O(1)$	$O(1)$


BFS y DFS sobre un árbol

BFS explora nivel por nivel usando una cola (FIFO) ·

DFS explora en profundidad usando una pila o recursión

Mismos algoritmos usados en la búsqueda en espacios de estados (Unidad 2)

Árbol de ejemplo (raíz en coral) — BFS: 12,2,18,6,0,8,3 · DFS: 12,2,6,0,3,18,8



¿Dónde profundizar cada tema?

Tema	Notebook del curso
Sesgo y varianza, sobre/subajuste	Unidad 4/1-fundamentos-redes-neuronales.ipynb
Métricas de clasificación	Unidad 3/6-pipelines-evaluacion.ipynb
PCA	Unidad 3/4-aprendizaje-no-supervisado.ipynb
Teorema de Bayes	Unidad 3/1-AI-fundamentals/3-teorema-bayes.ipynb
Regresión y regularización	Unidad 3/3-aprendizaje-supervisado/1-regresion-avanzada.ipynb
CNN y arquitecturas	Unidad 4/3-redes-convolucionales.ipynb
Ensamblés	Unidad 3/5-modelos-ensamble.ipynb
Estructuras de datos, BFS/DFS	Unidad 2/1_buscar-estados-ia.ipynb

¡Gracias!

Este material acompaña el notebook Cheat Sheet.ipynb del curso.