

Agentic AI

Unidad 5 — Agentes de IA: razonamiento, memoria, herramientas y evaluación.

Contenido

01 Fundamentos de agentes (ReAct)

02 Memoria y estado

03 Múltiples herramientas

04 Grafos con LangGraph

05 RAG como herramienta

06 Sistemas multiagente

07 Evaluación de agentes

01

Fundamentos de Agentes (el patrón ReAct)


¿Qué le agrega un agente a un LLM?

Un LLM aislado solo produce texto a partir de texto — no puede consultar información actualizada ni ejecutar acciones

Un agente le agrega tres cosas:

- Herramientas: funciones que puede invocar (calculadora, búsqueda, base de datos)
- Un ciclo de decisión: decide en cada paso si ya puede responder o necesita usar una herramienta
- Autonomía: el LLM elige qué herramienta usar y con qué argumentos, sin una secuencia programada de antemano

El patrón ReAct: razonar y actuar en ciclos



Intercalar razonamiento entre cada acción permite que el agente replantee su estrategia si una herramienta no devolvió lo esperado, en vez de seguir ciegamente.

El ciclo ReAct, en una conversación real

Calcula el área de un círculo de radio 5 y explica por qué usas esa fórmula.

 `calcular_area_circulo(radio=5) → 78.54`

Para calcular el área de un círculo, utilizamos $A = \pi \cdot r^2$. El resultado es 78.54 unidades cuadradas...

02

Memoria y Estado

Sin checkpointer, el agente olvida

- Cada invocación de un agente es, por defecto, independiente de las anteriores
- Un checkpointer (p. ej. InMemorySaver) guarda el historial de mensajes entre invocaciones, asociado a un thread_id
- En la siguiente invocación con el mismo thread_id, LangGraph recupera ese historial automáticamente

Real: mismo agente, con y sin memoria

Sin memoria (cada turno, un agente nuevo)

Hola, me llamo Sebastian.

¡Hola, Sebastian! ¿En qué puedo ayudarte?

No lo sé. ¿Cómo te llamas?

¿Cuál es mi nombre?

Con memoria (mismo thread_id)

Hola, me llamo Sebastian.

¡Hola, Sebastian! ¿En qué puedo ayudarte?

¿Cuál es mi nombre?

Te llamas Sebastian.

Cada `thread_id` es una conversación aislada

`thread_id: conversacion-1`

Sabe que es Sebastian

`thread_id: conversacion-2`

No sabe el nombre

- El mismo agente y el mismo checkpointer pueden sostener muchas conversaciones en paralelo
- Esto permite que una aplicación (p. ej. un chatbot de soporte) atienda a muchos usuarios distintos sin mezclar sus historiales
- En producción se usa un checkpointer persistente (disco o base de datos) en vez de `InMemorySaver`, para no perder el historial al reiniciar el proceso

03

**Múltiples
Herramientas**

¿Cómo elige el agente entre varias herramientas?



El LLM decide, a partir del nombre, el docstring y los argumentos de cada herramienta, cuál (si alguna) usar — no hay un if/else programado. Un docstring claro y específico es lo que permite que esa elección sea correcta.

Resultados reales de enrutamiento


Pregunta	Herramienta invocada	Respuesta
Convierte 100 USD a COP (tasa 4000)	convertir_moneda	400,000 pesos colombianos
¿Cuántas palabras tiene la frase...?	contar_palabras	6 palabras
Área de un círculo de radio 3	calcular_area_circulo	≈28.27
¿Qué hora es en Bogotá?	(ninguna)	"No tengo acceso a esa información"

En los tres primeros casos, el agente invocó exactamente la herramienta correcta con los argumentos correctos. En el cuarto, correctamente reconoció que ninguna herramienta disponible podía responder, en vez de inventar una hora.

04

**Grafos con
LangGraph**

Un agente es, por dentro, un grafo




- Estado: los datos compartidos entre nodos — aquí, la lista de messages
- Nodos: funciones que reciben el estado y devuelven una actualización — modelo (llama al LLM) y herramientas (ejecuta la acción pedida)
- Aristas condicionales: deciden a qué nodo ir según el contenido del estado — **tools_condition** revisa si el LLM pidió una herramienta
- `create_agent` construye, internamente, un grafo prácticamente igual a este

05

**RAG como
Herramienta**

El flujo de RAG (Retrieval-Augmented Generation)



- El documento se divide en fragmentos, cada uno se convierte en un vector (embedding) que captura su significado
- Al hacer una pregunta, se recuperan los fragmentos más similares semánticamente (no por coincidencia exacta de palabras)
- Esos fragmentos se envuelven en una función @tool más — para el agente, RAG es una herramienta como cualquier otra

Real: sin RAG inventa, con RAG acierta

"¿Cuántos meses de garantía tienen los auriculares NimbusTech Aria-7 y por qué?" (marca ficticia, creada para este notebook)

Sin RAG

Necesito más contexto... en la Unión Europea la garantía legal suele ser de 3 años... [generaliza sin saberlo]

Con RAG

Los auriculares NimbusTech Aria-7 tienen una garantía extendida de 30 meses, debido a su batería de estado sólido.

06

**Sistemas
Multiagente**

Patrón: agentes como herramientas



- Cada especialista es un agente con las herramientas de un solo dominio — más fácil que elija bien entre pocas opciones
- El supervisor no ve las herramientas internas de cada especialista, solo dos herramientas de alto nivel: "consultar a finanzas" y "consultar a texto"

Real: el supervisor delega correctamente

Convierte 200 USD a COP con tasa 4000, y dime cuántas palabras tiene: "los agentes trabajan en equipo"

```
→ consultar_especialista_finanzas("Convierte 200 USD a COP con  
tasa 4000")
```

```
→ consultar_especialista_texto("¿Cuántas palabras...?")
```

200 dólares equivalen a 800,000 pesos colombianos. La frase "los agentes trabajan en equipo" tiene 5 palabras.

El supervisor repartió correctamente cada parte de la pregunta compuesta al especialista adecuado, sin lógica programada a mano.

07

**Evaluación de
Agentes**

Dos dimensiones: trayectoria y resultado

- Corrección de la trayectoria: ¿el agente invocó la herramienta correcta (o correctamente ninguna)?
- Corrección del resultado: ¿la respuesta final es correcta?
- Un agente puede llegar a la respuesta correcta por el camino equivocado — o elegir bien la herramienta y aun así redactar mal la respuesta
- Evaluación determinista (reglas programadas) en vez de "LLM como juez": más simple y barata cuando la respuesta se puede verificar con una regla exacta

Resultado real sobre 4 casos de prueba

100%

Exactitud de trayectoria

100%

Exactitud de resultado

Pregunta	Trayectoria	Resultado
Área de un círculo de radio 6	OK	OK
Convierte 50 euros a pesos (tasa 4300)	OK	OK
Palabras en "hola mundo desde el agente"	OK	OK
¿Qué tiempo hace hoy en Medellín?	OK (ninguna herramienta)	OK

Resumen de la Unidad 5

Tema	Notebook del curso
Fundamentos de agentes (ReAct)	1-fundamentos-agentes.ipynb
Memoria y estado	2-memoria-y-estado.ipynb
Múltiples herramientas	3-multiples-herramientas.ipynb
Grafos con LangGraph	4-grafos-langgraph.ipynb
RAG como herramienta	5-rag-como-herramienta.ipynb
Sistemas multiagente	6-multiagentes.ipynb
Evaluación de agentes	7-evaluacion-de-agentes.ipynb

¡Gracias!

De razonar y actuar en ciclos, a coordinar equipos de agentes — el cierre del curso.